

인공지능특론 (Advanced Artificial Intelligence) 11주 신경망 소개





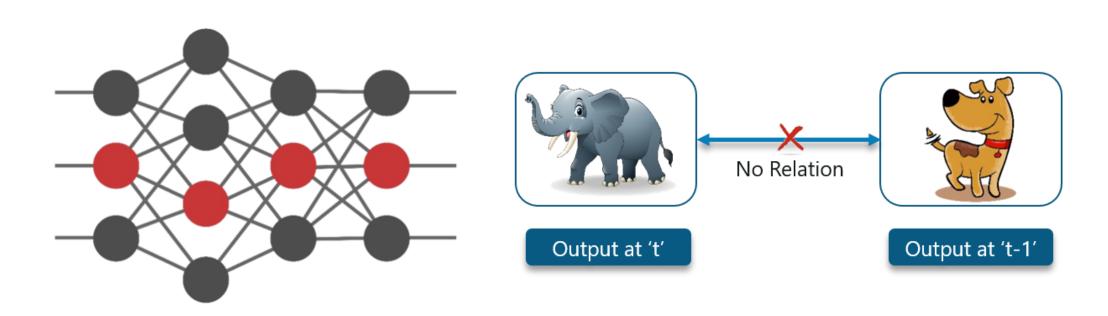
10 시계열 데이터 기반 RNN 이해

Why Not Feedforward Networks



❖ 기존 FeedForwared Networks에서는

- ✓ 입력은 개 이미지이고, 학습이 잘된 신경망은 개의 라벨을 출력한다.
- ✓ 바로 다음 코끼리 이미지를 입력을 사용하면 코끼리(라벨)을 출력한다.
- ✓ 하지만 코끼리와 개는 서로 관련성이 없고 독립적이다.

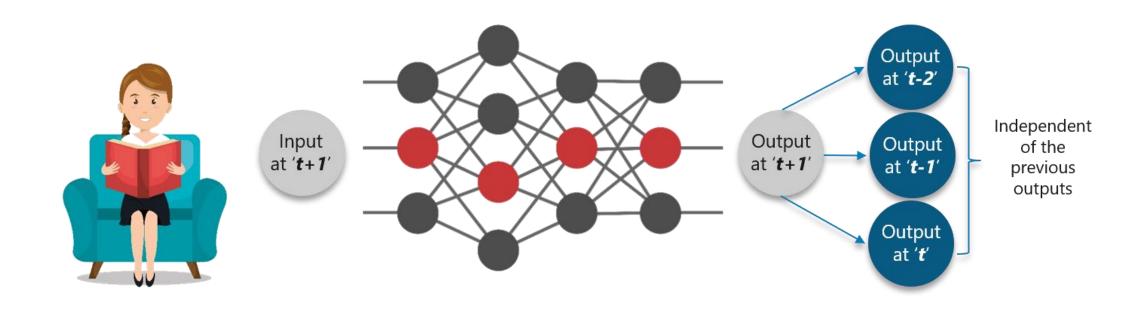


ref: https://www.edureka.co/blog/recurrent-neural-networks/

Why Not Feedforward Networks



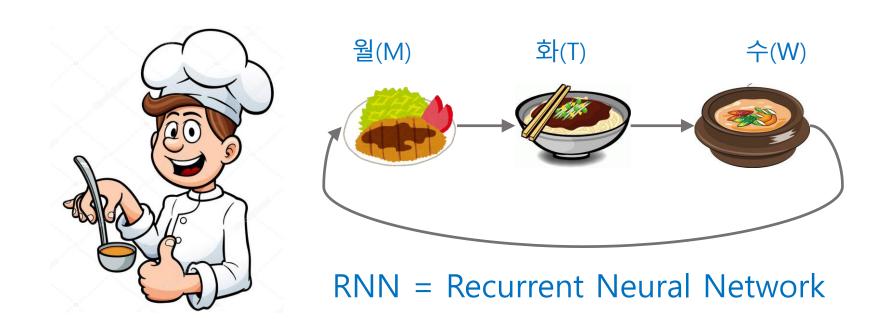
- ❖ 책을 읽고 있을 경우, 이전 페이지의 내용을 잘 알고 있어야 한다.
 - ✓ 책의 문맥을 이해하기 위해서는 이전의 내용 및 이전 단어를 기억하고 있어야 한다.
 - ✓ 그래서 Feeforward 네트워크는 이전 단어들로 다음 단어의 관계를 예측해 줄 수 없다.
 - ✓ 즉 이전의 내용(단어)를 기억해 줄 수 있는 네트워크가 필요하다.



간단한 순환신경망(RNN)



- ❖ 함께 살고 있는 룸메이트는 요리를 하느데 3종류만 할 줄 안다.
 - ✓ 친구는 저녁을 하는데 3가지 음식만 만든다.
 - ✓월요일은 돈까스, 화요일은 짜장면, 수요일은 찌게 등 순차적으로 3가지 음식을 반복한다.
 - ✓ 룸메이트가 기억하고 있는 패턴은 단순하다.



간단한 순환신경망(RNN)



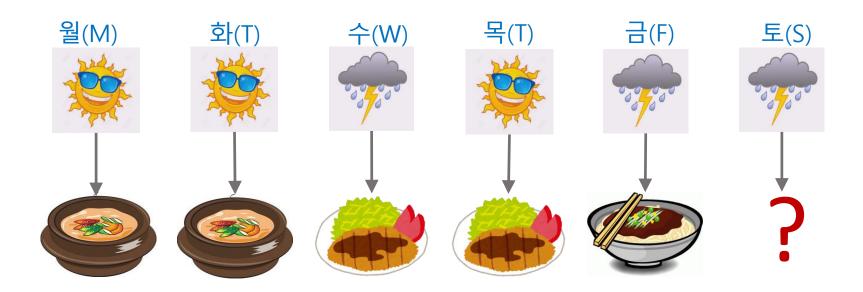
- ❖ 실제로 룸메이트는 날씨에 따라서 식사 메뉴에 규칙을 가지고 있다.
 - ✓ 날씨가 좋은 날은 야외활동해서 늦게 귀가하며 전날 먹은 음식을 다시 먹는다.
 - ✔ 하지만 비가 오는 날은 일찍 집에 귀하하여 원래 패턴을 따라서 음식을 만든다.



RNN depending on the weather

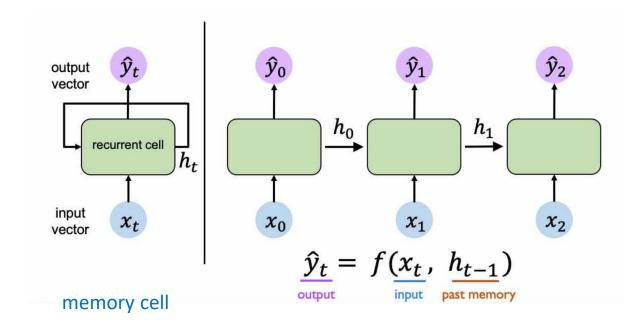


- ❖ 나는 오늘 아침 날씨에 따라서 저녁에 먹을 음식을 예측할 수 있다.
 - ✓월요일은 저녁에 찌게를 먹었고, 화요일 아침 날씨가 좋아서 저녁에도 찌게를 먹었다.
 - ✔수요일은 비가와서 원래 패턴인 돈까스, 목요일은 좋은 날씨라서 어제 먹은 돈까스
 - ✓ 금요일은 비가와서 원래 패턴인 짜장면을 먹었다.
 - ✓ 토요일에 비가 왔는데 저녁 메뉴는 무었인가?



Neurons with Recurrence





Output Vector

$$\hat{y}_t = \boldsymbol{W}_{hy}^T h_t$$

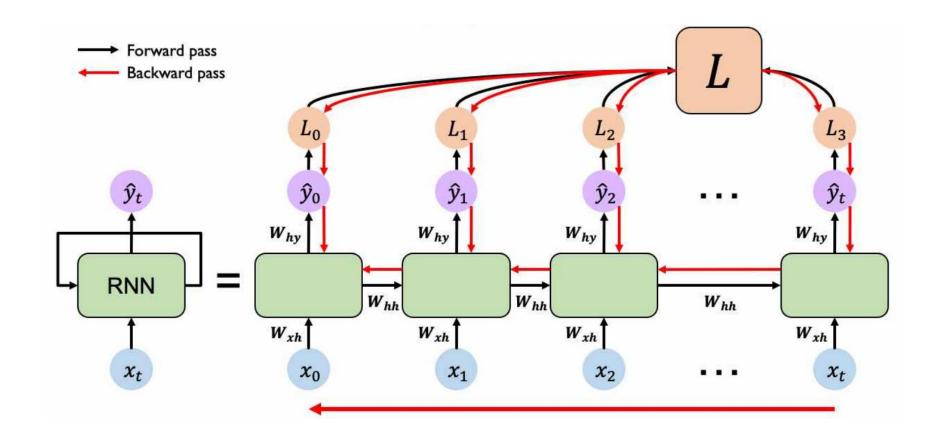
Update Hidden State

$$h_t = \tanh(\boldsymbol{W}_{hh}^T h_{t-1} + \boldsymbol{W}_{xh}^T x_t)$$

Input Vector x_t

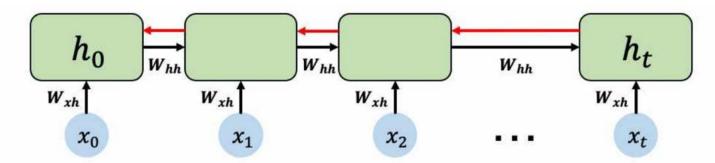
Backpropagation Through Time





Standard RNN Gradient Flow: Expoding Gradients



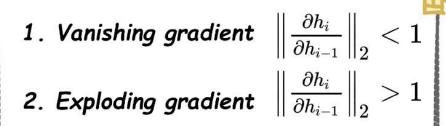


Computing the gradient wrt h_0 involves many factors of W_{hh} + repeated gradient computation!

$$\frac{\partial L^{(t)}}{\partial \mathbf{W}_{hh}} = \frac{\partial L^{(t)}}{\partial y^{(t)}} \cdot \frac{\partial y^{(t)}}{\partial \mathbf{h}^{(t)}} \cdot \left(\sum_{k=1}^{t} \frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} \cdot \frac{\partial \mathbf{h}^{(k)}}{\partial \mathbf{W}_{hh}} \right)$$

computed as a multiplication of adjacent time steps:

$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} = \prod_{i=k+1}^{t} \frac{\partial \mathbf{h}^{(i)}}{\partial \mathbf{h}^{(i-1)}}$$



2. Exploding gradient
$$\left\|rac{\partial h_i}{\partial h_{i-1}}
ight\|_2>1$$

Solutions to the vanishing/exploding gradient problems

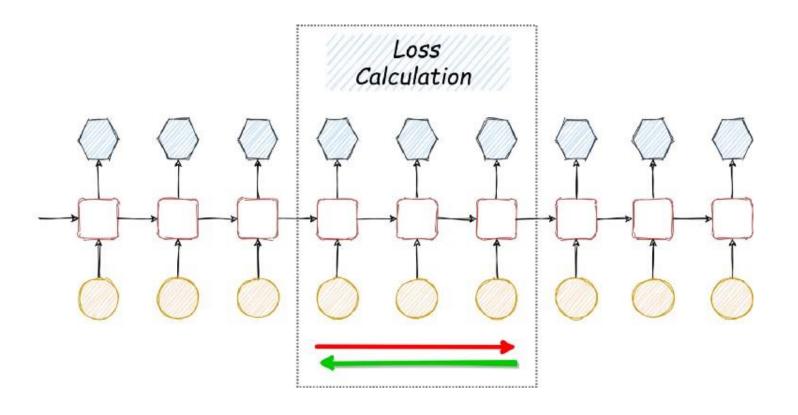


- Truncated backpropagation through time (TBPTT)
 - ✓ simply limits the number of time steps the signal can backpropagate after each forward pass.
- Long short-term memory (LSTM)
 - ✓ uses a memory cell for modeling long-range dependencies and avoid VGP
- Gradient Clipping
 - ✓ set a max value for gradients if they grow to large

Truncated Backpropagation Through Time



Truncated BPTT trick tries to overcome the VGP by considering a moving window through the training process



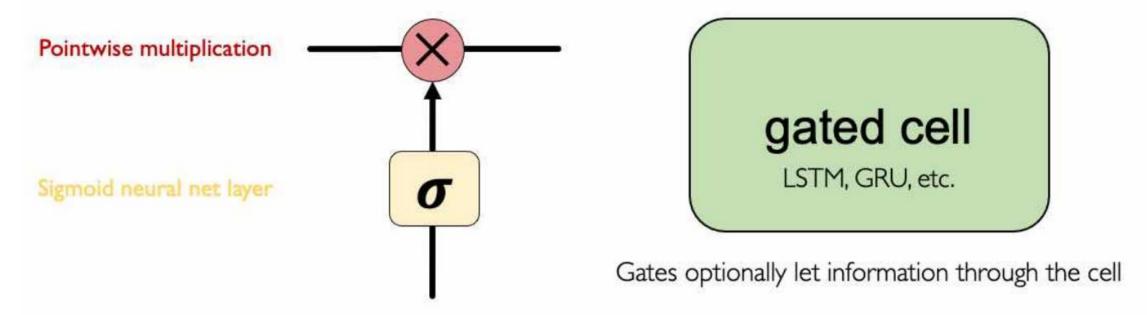


13 LSTM로 교통 흐름 예측

Trick: Gated Cells



Idea: use gates to selectively add or remove information within each recurrent unit with



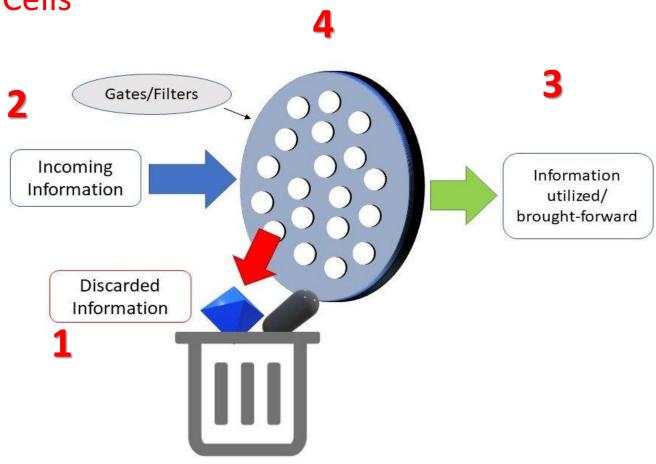
Long Short Term Memory (LSTMs) networks rely on a gated cell to track information throughout many time steps.



Gates control the flow of information to/from the memory

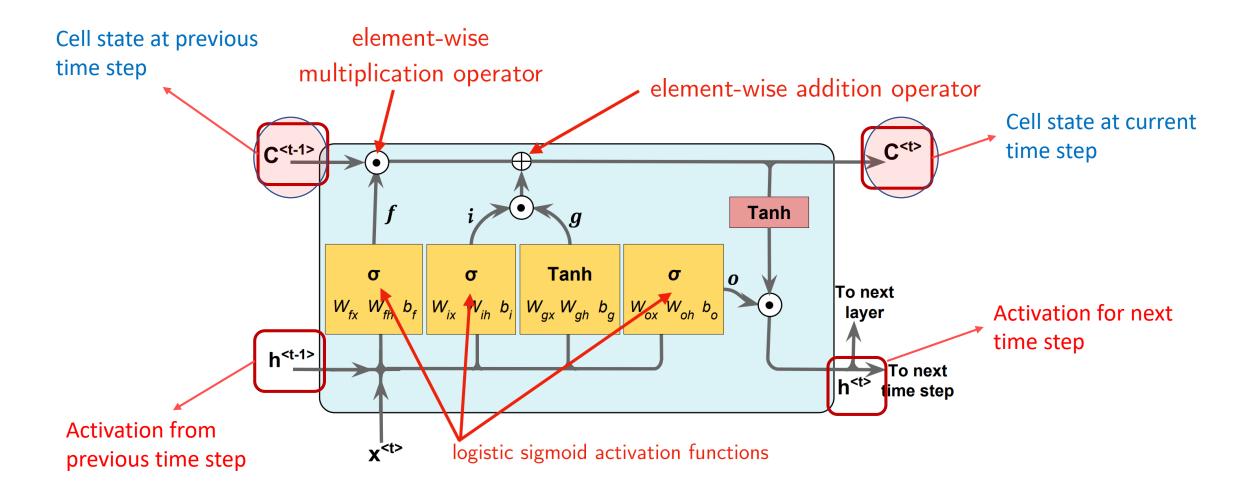






Long-short term memory (LSTM) : Cell state





핵심 사항 정리



❖ 데이터 전처리

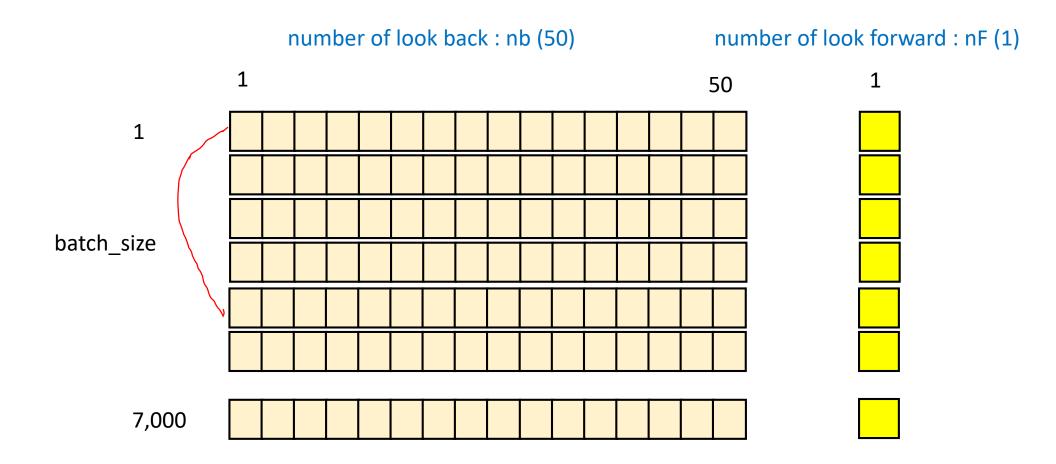
- ✔시계열 데이터의 과거 기억의 길이를 windows 한다면, 그 길이는 중요한 파라미터이다.
 - windows=12 (1시간)을 권장한다.
- ✔RNN의 한계점을 극복하고 LSTM의 장점을 반영하기 위해서는 긴 기억 계산을 시도해 보자
 - windows=144 (12시간)을 설정하면 컴퓨터 계산 시간이 많이 필요로 한다.
- ✔ Many-to-One 형태의 응용 모델로 설계하자.
 - 과거 기억으로 바로 다음 순간(미래) 값을 예측한다.
- ✓ 단항(Uni-variant) 값을 사용한 \ .
 - 여기서는 속도만을 고려한다.

❖ LSTM 모델 설정 및 모델 이해

- ✔ return_sequences=True는 Many-to-Many 형태에서 이전 Layer의 정보를 다음 층에 전달한다.
 - 웨이트가 초기화할 필요없이 유지된다.
- ✔디폴트 활성함수는 tanh이다. relu도 사용할 수 있지만 GPU에서 Blas를 이용한 고속 처리는 안 된다.
- √ 뉴런에 대하여
 - 각각 LSTM에서 기억의 길이마다 뉴런 개수를 정할 수 있다. (여기서는 60으로 설정함)
 - 출력층은 1개의 뉴런을 갖는다. (Many-to-One 문제임)

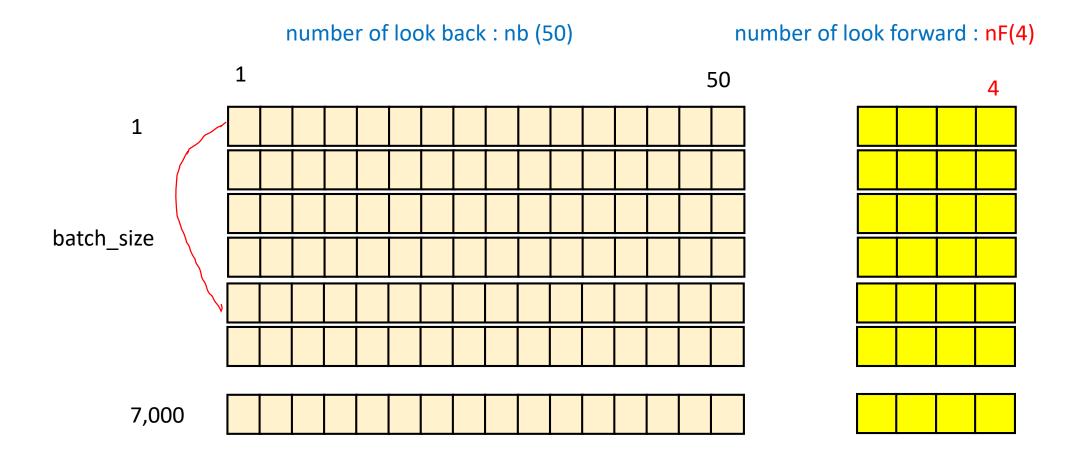
Many-to-One RNN Data Structure





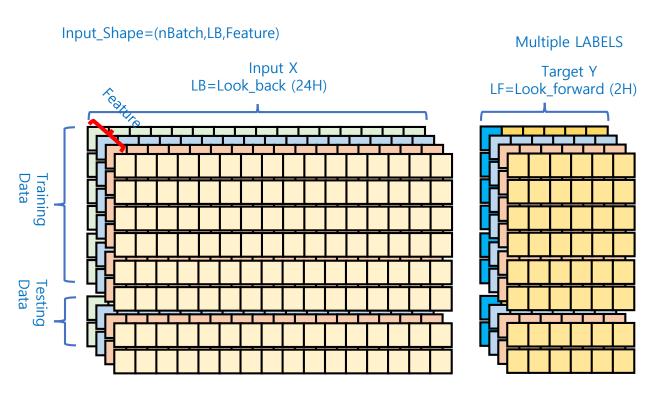
Many-to-Many RNN Data Structure





RNN Input-Output Data Structure





VDS, RSE Data Preprocessing for LSTM



RNN으로 교통흐름 예측 실습

- VDS 데이터, SimpleRNN

VDS 데이터 다운로드



```
In [1]: ▶ import tensorflow as tf
```

In [2]:

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

Out[3]:

		Date	ToVol	SmVol	MeVol	LaVol	Speed	Occ.Rate
0	2017-04-02	0:00	43	34	9	0	50.3	1.90
1	2017-04-02	0:05	45	32	13	0	58.9	1.84

차량 속도를 입력으로 사용



```
In [4]:

df_uni = df.iloc[:,5:6].values

In [5]:
         ▶ df_uni
   Out [5]: array([[50.3],
                   [58.9],
                   [50.6],
                   ...,
                   [50.6],
                   [59.3],
                   [52.5]])
In [6]:
         ▶ print(df_uni.shape)
            (8064, 1)
```

입력을 정규화



```
In [7]:
         ▶ from sklearn.preprocessing import MinMaxScaler
            scaler = MinMaxScaler(feature_range = (0,1))
            scaled_df = scaler.fit_transform(df_uni)
            scaled_df
   Out [7]: array([[0.52350699],
                   [0.63278272],
                   [0.52731893],
                   [0.52731893],
                   [0.63786531],
                   [0.55146125]])
```

RNN 데이터 구조 만들기



```
In [8]:
          look_back = 144
In [9]:
          M X = []
             y = []
             for i in range(len(scaled_df)-look_back-1):
                 X.append(scaled_df[i:(i+look_back)])
                 y.append(scaled_df[(i+look_back)])
            X = np.array(X)
             y = np.array(y)
In [10]:
          ▶ print(X.shape, y.shape)
             (7919, 144, 1) (7919, 1)
```

훈련과 테스트 데이터 나누기



```
In [11]:
         ▶ from sklearn.model_selection import train_test_split
            X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, shuffle=False)
            print(X_train.shape, y_train.shape)
            print(X_test.shape, y_test.shape)
             (6335, 144, 1) (6335, 1)
             (1584, 144, 1) (1584, 1)
In [12]: M neuron_1 = 32
            neuron_2 = 16
```

간단한 RNN 모델 아키텍처 : SimpleRNN



```
In [13]:
          ▶ from tensorflow.keras.layers import Dense, SimpleRNN, LSTM
             from tensorflow.keras.models import Sequential
In [14]:
             def simple_rnn():
                 model = Sequential([
                     SimpleRNN(neuron_1, input_shape=(X_train.shape[1],1)),
                     Dense(neuron_2),
                     Dense(1)
                 ])
                 model.compile(optimizer='adam', loss= 'mse', metrics=['mae'])
                 return model
```

모델 파리미터 계산



```
In [15]:
```

model = simple_rnn()
model.summary()

Model: "sequential"

Layer (type)	Output Shape	Param #
simple_rnn (SimpleRNN)	(None, 32)	1088
dense (Dense)	(None, 16)	528
dense_1 (Dense)	(None, 1)	17

Total params: 1,633

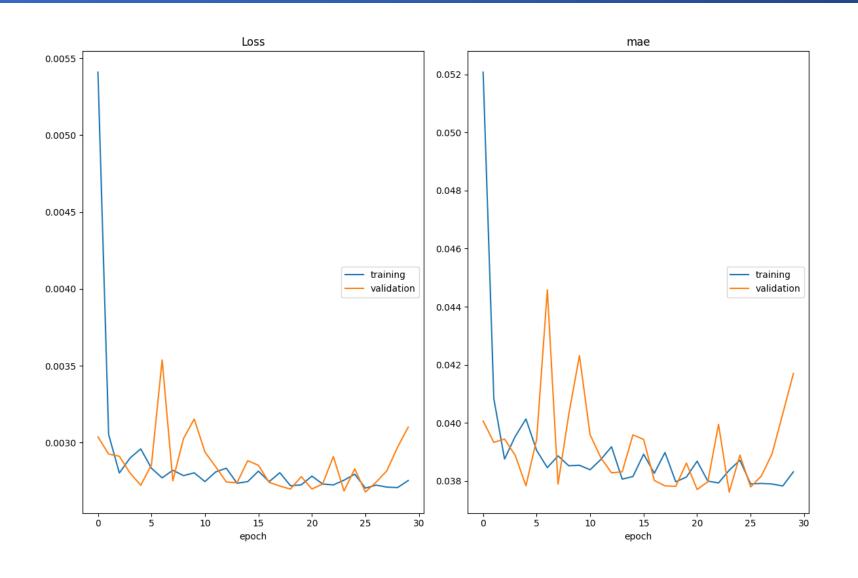
Trainable params: 1,633 Non-trainable params: 0

모델 훈련과 실시간 가시화



PlotLossesKeras 결과





훈련과정 손실값



```
Loss
                                 0.005, cur:
    training
                        0.003, max:
                                          0.003)
                   (min:
    validation
                   (min:
                        0.003, max:
                                 0.004, cur:
                                          0.003)
mae
    training
                   (min:
                        0.038, max:
                                0.052, cur: 0.038)
                   (min:
    validation
                        0.038, max: 0.045, cur: 0.042)
```

숙제 제출 할 때 사용할 것

테스트 데이터 활용한 예측



```
In [18]:
       Out[18]: (1584, 144, 1)
In [19]:
       # Prediction
         y_pred = model.predict(X_test)
         50/50 [======== ] - 1s 11ms/step
In [20]:
       Out [20]: (1584, 1)
In [21]:
       Out [21]: (1584, 1)
```

예측값 대 실제값 비교

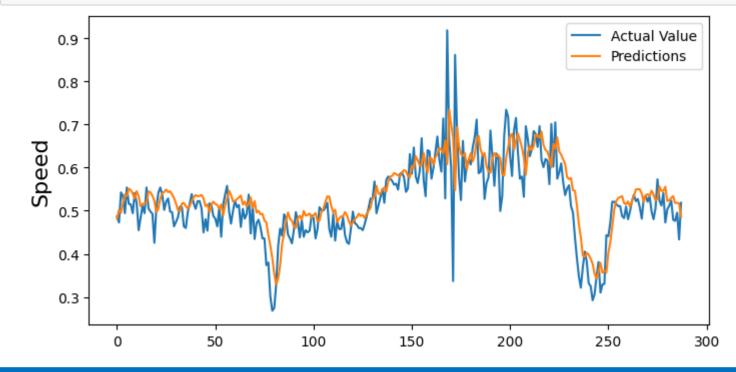


Out [22]:

	Actual	Predicted
0	0.486658	0.481714
1	0.472681	0.502077
2	0.542567	0.495385
3	0.533672	0.517115
4	0.494282	0.538158

정규화된 차량 속도 예측





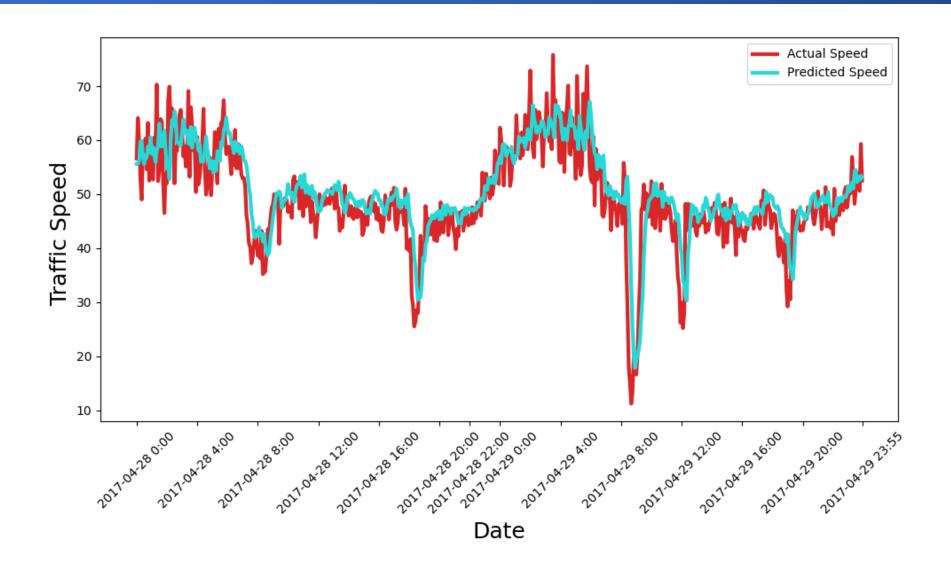
차량속도 원래 값으로 예측



```
y_pred = scaler.inverse_transform(y_pred)
            50/50 [========== ] - 1s 10ms/step
In [25]:
        ▶ plt.figure(figsize=(15, 8))
           #plt.style.use("dark background")
           plt.plot(df["Date"].iloc[-576:], df_uni[-576:], linewidth= 5, color='#d92628', label='Actual Speed')
           plt.plot(y_pred[-576:], color='#26D9D7', linewidth= 5, label='Predicted Speed')
           plt.xlabel("Date", size="18")
           plt.ylabel("Traffic Speed ", size="18")
           plt.xticks([0, 24, 48,72, 96,120, 144, 168, 192,216,240,264, 287],rotation=45)
           plt.tight_layout()
           plt.legend()
```

실제값으로 차량 속도 예측 (2일)





원래 속도로 환원

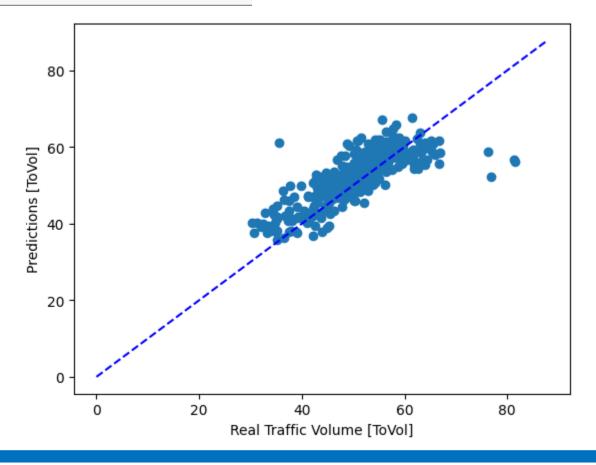


```
y_pred = model.predict(X_test, verbose=0)
print(y_pred.shape,y_test.shape)
(1584, 1) (1584, 1)
y_pred = scaler.inverse_transform(y_pred)
y_test = scaler.inverse_transform(y_test)
pred_df = pd.DataFrame({'Actual': y_test.flatten(), 'Predicted': y_pred.flatten()})
pred_df.head()
   Actual Predicted
    47.4 47.543636
```

실제값과 예측 오차



```
plt.scatter(y_test.flatten()[:576], y_pred.flatten()[:576])
plt.xlabel('Real Traffic Volume [ToVol]')
plt.ylabel('Predictions [ToVol]')
plt.plot([0, max_speed], [0, max_speed], 'b--')
```



숙제



- ❖ SimpleRNN 하이퍼파라미터 최적화
 - ✓ 속도(Speed)와 교통량에 대하여 아래 표를 작성하세요
 - Look_back은 수정하지 말것
 - 뉴런 개수와 은닉층은 수정 가능함
 - ✓ 가장 작은 MSE 값을 제출하고 그때 파이미터 값도 제시함

항목	Look_back	뉴런	은닉층	MSE
Speed	12			
Speed	288			
ToVol	288			

print("\nlook_back={:3d}, MSE={:8.6f}".format(look_back,mse))

look_back=144, MSE=0.002782



